高级算法课程

实验报告

实验一：用 minHash 实现集合的相似性连接

姓名：朱宸慷

学号：2021110908

班级：2103103

评分表：（由老师填写）

最终得分：	
对实验题目的理解是否透彻：	
实验步骤是否完整、可信 ：	
代码质量 ：	
实验报告是否规范 ：	
趣味性、难度加分 ：	
特 色：	1
	2
	3

一、实验题目概述

分别实现两重循环算法和 minHash 方法求解如下计算问题，利用教师发布在教学 QQ 群中的三个公开实验数据集(AOL, DILICIOUS, LINUX)开展对比实验和扩展性实验，观察 Hash 函数个数对算法性能的影响，并根据实验结果讨论经验参数设置办法。

二、对实验步骤的详细阐述

整体步骤

1. 实现 Naïve 算法(两重循环计算交集大小)
2. 实现 minHash 算法求解问题，比较两种算法的计算结果是否一致，并解释观察到的现象
3. 设置不用的 Hash 函数个数，比较返回结果的差别和运行效率的差别，总结得出 Hash 函数个数的最佳经验设置公式
4. 更换数据集，验证上述公式的一致性
5. 抽取数据集中不同比例的数据子集开展实验，讨论方法的扩展性
6. 撰写实验报告

collector 思想

1. 从文件中读取形如<setId,setItem>的数据集，构建形如<setId,[setItem]->set>的哈希表，实现一个可复用的数据收集器。
2. 根据入参确定路径以及读取方式，包括在：算法开始前读取数据，比较时读取 minhash 结果，比较时读取 naïve 结果
3. 不能直接存取类成员，需要通过 get_keys(),get_allvalues()方法获取成员

minHash 算法

1. 从哈希表中随机抽样 n_sample 项，提取这些 key 对应的 value 的集合，将这些集合合并后去重，称为 allValue 数组。
2. 随机打乱 allValue 数组，构成一个哈希函数。此处由于 allValue 足够大，可以相信其在每次实验中都是互异的，为了降低复杂性不再检查是否产生重复。
3. 从前遍历 allValue 数组，记录元素的 index，基于集合的 O(logn)查找来判断该元素在哈希表的 value 中是否存在。若存在，则将 index 记录为该 set 在该哈希函数下的 minHash 值
4. 对本次抽样的所有集合都计算一轮本哈希函数下 minHash 值并保存
5. 完成所有哈希函数的计算后计算相似性并输出

Naïve 算法

1. 从哈希表中随机抽样 n_sample 项，此处步骤由 collector 完成，保证与 minHash 算法使用相同的数据
2. 分别计算每两个集合之间的相似性并输出

三、实验数据

1. 实验设置

实验环境：

Python 3.11

Windows 11

数据：

E1_AOL-out.txt　　E1_Booking-out.txt　　E1_kosarak_100k.txt

2. 实验结果

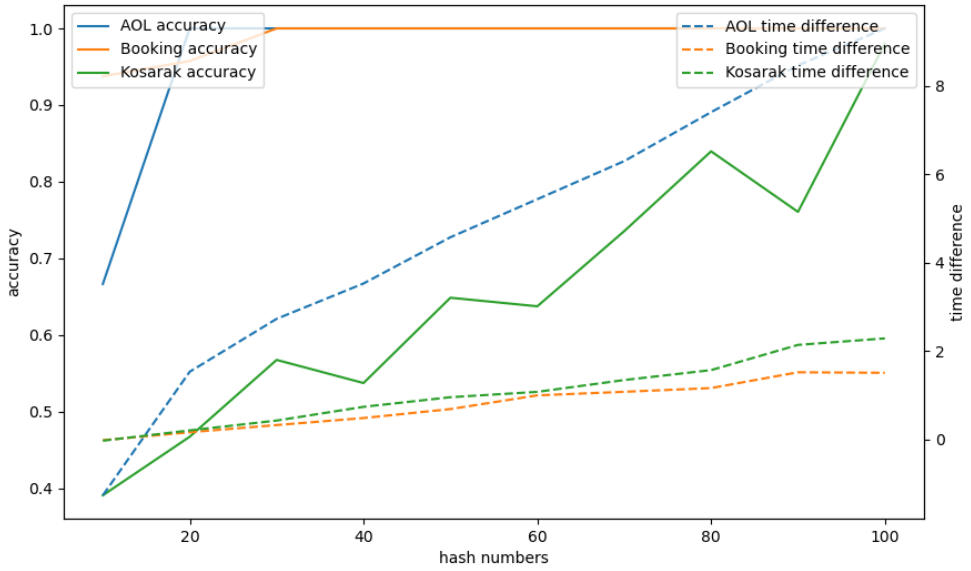

四、对实验结果的理解和分析

1. 随着哈希函数数量的增加，三个数据集的准确率都在提升
2. 算法在 AOL 和 Booking 数据集的表现良好，在 Kosarak 上则一般。根据在过程中生成的文件可以推断以下结论
   a) 前二者相似的集合较少，容易达到较高的正确率

9	21080	63386
10	64185	63386
11		

44	287295	287154
45	188020	188332
46		

   b) Kosarak 数据集即使在 100 个哈希函数的情况下，仍然会产生四百余个相似的集合，在比较准确率的基数上就不占优势

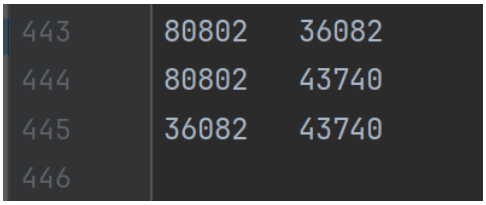

3. Naïve 算法在 AOL 数据集上表现良好，在另外两个数据集表现一般。在哈希函数大幅增加的情况 naive 算法下与 minHash 算法的时间差基本保持稳定
4. 综合来看，数据集 Kosarak 比较有参考价值。因此可以得出结论，哈希函数在 80 左右较好，此时准确率超过 80%且到达极值点。此时更改哈希函数数量会导致准确率下降。如果将哈希函数的数量提升到 100 左右，那么一方面运行时间会大幅增加，并且此时对于准确率的提高也有限，同时相对于 naïve 算法的时间优势也在降低。

五、实验过程中最值得说起的几个方面

1. 编写代码时算法的时间复杂度经过了多次优化。其中包括收集数据后 O(logn)建立集合，基于集合使用 O(logn)查找来代替 O(n)的遍历等集合操作来代替数组遍历操作。
2. Collector 模块的设计理念是复用代码，返回哈希表。但是在这一思想的前提下，过程中生成的中间文件的结果三元组(setId,setId,[simItems]->set)不能很好的满足构建哈希表的要求，于是舍弃能精确计算准确率的[simItems]->set 部分，从而使 Collector 模块代码可以重入。
3. 本实验为了保证执行效率通过调用 Numba 库将部分函数编译为了机器码，跳过了 python 解释器的翻译步骤，从而加快执行效率。
4. 目的同上，本实验还有一个部分完成的 Go 语言实现。